
Clasificación de llantas dañadas mediante reconocimiento de textura: un estudio comparativo entre una CNN diseñada desde cero y transferencia de aprendizaje con ResNet-50

Paul Bazan H. Valeria P. Bulege N. Oscar Dante Chaíña A.

Eliás O. Díaz C. Miguel A. Tasayco M.

Grupo N.º 1 — Maestría en Inteligencia Artificial (2026-1)

Escuela de Posgrado, Universidad Nacional de Ingeniería (UNI), Perú

Examen Parcial — Redes Neuronales y Aprendizaje Profundo

Resumen

La inspección visual del estado de las llantas es costosa, subjetiva y difícil de escalar. Este trabajo aborda la clasificación binaria automática entre llantas en buen estado (*normal*) y dañadas/agrietadas (*cracked*) a partir de imágenes de textura superficial. Se implementan y comparan dos arquitecturas: una red convolucional (CNN) diseñada íntegramente desde cero y un modelo ResNet-50 preentrenado en ImageNet con *fine-tuning* parcial. Sobre el conjunto de prueba oficial (325 imágenes), ResNet-50 alcanza una exactitud de 0.782, F1 de 0.803 y AUC-ROC de 0.946, superando ampliamente a la CNN propia (0.649 / 0.661 / 0.764). Se realiza un estudio de ablación sobre dos factores (estrategia de aumento de datos y función de pérdida), un análisis cuantitativo del desbalance de clases —que en este conjunto se invierte entre entrenamiento y prueba— evaluando tres estrategias de mitigación, e interpretabilidad mediante Grad-CAM. Los mapas de activación muestran que el modelo localiza correctamente las grietas. El análisis cualitativo de errores revela que los fallos más confiados son falsos negativos sobre flancos con relieve y grietas finas, una limitación crítica para una aplicación de seguridad.

1 Introducción y motivación

El desgaste y el agrietamiento de las llantas constituyen un factor de riesgo directo para la seguridad vial: el deterioro del flanco y de la banda de rodadura reduce la adherencia y aumenta la probabilidad de reventones. En entornos industriales y de mantenimiento de flotas, la inspección manual es lenta, depende de la experiencia del operario y resulta difícil de auditar y escalar. Un sistema capaz de discriminar automáticamente, a partir de una imagen de la textura superficial, entre una llanta sana y una agrietada permitiría priorizar inspecciones, documentar decisiones y reducir la subjetividad.

El problema es atractivo desde la perspectiva del aprendizaje profundo porque la señal discriminante es esencialmente textural —patrones de fisuras, oxidación y pérdida de relieve— y de escala fina. En este trabajo no nos limitamos a entrenar un clasificador: (i) implementamos una CNN desde cero y un modelo de transferencia de aprendizaje, comparándolos de forma rigurosa con métricas adecuadas a un escenario potencialmente desbalanceado; (ii) estudiamos por ablación el efecto del aumento de datos y de la función de pérdida; (iii) cuantificamos el impacto del desbalance de clases y evaluamos tres estrategias de mitigación; (iv) interpretamos las decisiones mediante Grad-CAM; y

Tabla 1: Distribución de clases. Nótese la *inversión* del desbalance: la mayoría es *normal* en entrenamiento y *cracked* en prueba.

Partición	<i>cracked</i>	<i>normal</i>	Total
Entrenamiento (oficial)	327	376	703
↪ entren. (85%)	278	320	598
↪ valid. (15%)	49	56	105
Prueba (oficial)	210	115	325

(v) realizamos un análisis cualitativo de fallos. Todo el código es reproducible de extremo a extremo con un único comando.

Contribuciones. (1) Una CNN residual ligera diseñada desde cero (~ 0.71 M parámetros) adaptada a texturas. (2) Una comparativa rigurosa frente a ResNet-50 con *fine-tuning* parcial. (3) Un análisis del desbalance de clases con la observación, poco habitual, de una *inversión* del desbalance entre los conjuntos de entrenamiento y prueba, y su efecto sobre la calibración. (4) Evidencia visual (Grad-CAM) y un análisis de errores que identifica el modo de fallo dominante.

2 Trabajos relacionados

Arquitecturas convolucionales. Desde AlexNet [Krizhevsky et al., 2012] y VGG [Simonyan and Zisserman, 2015], las CNN profundas dominan la clasificación de imágenes. Las conexiones residuales de ResNet [He et al., 2016] permitieron entrenar redes muy profundas mitigando la degradación del gradiente; adoptamos un bloque residual ligero en nuestra red propia y empleamos ResNet-50 como *backbone*. La normalización por lotes [Ioffe and Szegedy, 2015] estabiliza y acelera el entrenamiento, y es un componente central de ambas arquitecturas.

Transferencia de aprendizaje y aumento de datos. Las características aprendidas en ImageNet [Deng et al., 2009] son altamente transferibles a tareas con pocos datos [Yosinski et al., 2014], lo que motiva el *fine-tuning* parcial cuando el conjunto objetivo es pequeño. El aumento de datos es una regularización estándar para reducir el sobreajuste [Shorten and Khoshgoftaar, 2019].

Desbalance de clases e interpretabilidad. El desbalance degrada el rendimiento de las CNN y existen estrategias de remuestreo y reponderación para mitigarlo [Buda et al., 2018]; la pérdida focal [Lin et al., 2017] reescala la entropía cruzada para enfocar el aprendizaje en ejemplos difíciles. Para explicar las predicciones empleamos Grad-CAM [Selvaraju et al., 2017], que produce mapas de activación de clase a partir de los gradientes de la última capa convolucional.

Clasificación de llantas. El conjunto utilizado proviene de imágenes de flancos y bandas de rodadura, oxidadas y no oxidadas [Siegel, 2021]; trabajos previos sobre datos equivalentes reportan que las variantes de ResNet ofrecen el mejor desempeño, mientras que arquitecturas como EfficientNet pueden no converger bien en este régimen de pocos datos. Nuestro estudio se distingue por incorporar un análisis formal de ablación, de desbalance y de interpretabilidad sobre el mismo conjunto.

3 Metodología

3.1 Conjunto de datos y preprocesamiento

El conjunto contiene 1028 imágenes etiquetadas en dos clases. Se respeta la partición oficial `training_data/testing_data`; el conjunto de entrenamiento se subdivide de forma estratificada en 85%/15% para entrenamiento y validación (selección de modelo y parada temprana), reservando `testing_data` como prueba no vista. La Tabla 1 resume la distribución. La clase positiva del problema es *cracked* (la condición de riesgo a detectar).

Todas las imágenes se decodifican una sola vez y se redimensionan a 128×128 píxeles; se normalizan con las estadísticas de ImageNet (requeridas por el *backbone* y aplicadas también a la CNN

propia para garantizar un preprocesamiento idéntico y una comparación justa). El aumento de datos (cuando se activa) emplea traslaciones aleatorias mediante relleno reflejado y recorte, y volteos horizontal y vertical —transformaciones sin remuestreo, apropiadas para texturas sin orientación canónica y eficientes en CPU.

3.2 Arquitecturas

CNN diseñada desde cero. Se compone de un *stem* convolucional con *stride* 2 seguido de *max-pooling* (que reduce el mapa de activación más costoso), tres bloques residuales (Conv–BN–ReLU $\times 2$ con conexión de atajo proyectada y *max-pooling*), *global average pooling* y un clasificador MLP con *dropout*. El uso de *global average pooling* en lugar de un aplanado denso reduce drásticamente el número de parámetros (0.71M) y el sobreajuste. Todos los componentes están implementados explícitamente, sin reutilizar redes existentes.

ResNet-50 con *fine-tuning* parcial. Partimos de ResNet-50 preentrenada en ImageNet [He et al., 2016, Deng et al., 2009] y reemplazamos la capa final por una lineal de dos salidas. Congelamos conv1, bn1, layer1, layer2 y layer3, y ajustamos layer4 y la capa lineal (14.97M de 23.51M parámetros entrenables). Esta elección responde a dos razones: con ~ 600 imágenes de entrenamiento, ajustar la red completa induce sobreajuste; y el *fine-tuning* parcial conserva los detectores de bordes/texturas genéricos de ImageNet, reduciendo además el costo de cómputo en CPU.

3.3 Entrenamiento

Se entrena con Adam ($\text{lr} = 10^{-3}$ para la CNN propia, 5×10^{-4} para ResNet-50; *weight decay* 10^{-4}), *scheduler* ReduceLROnPlateau sobre la F1 de validación y parada temprana. Se selecciona el modelo de mejor F1 de validación. Las semillas se fijan para reproducibilidad. Por las restricciones del entorno (CPU de un solo núcleo, sin GPU), las imágenes se mantienen en caché en memoria y el entrenamiento es reanudable mediante *checkpoints*.

3.4 Mitigación del desbalance e interpretabilidad

Se evalúan tres estrategias frente al desbalance: (i) entropía cruzada simple (sin mitigación, línea base); (ii) entropía cruzada ponderada por el inverso de la frecuencia de clase; y (iii) pérdida focal [Lin et al., 2017] con $\gamma = 2$ y ponderación α por clase. Para interpretabilidad implementamos Grad-CAM [Selvaraju et al., 2017] desde cero mediante *hooks*, tomando como capa objetivo la última convolución de layer4 (ResNet-50) o del último bloque (CNN propia).

4 Experimentos

La matriz experimental comprende cinco entrenamientos: el modelo principal de cada arquitectura y tres variantes de la CNN propia para la ablación y el análisis de desbalance. Las métricas se calculan sobre el conjunto de prueba oficial, con *cracked* como clase positiva: exactitud, precisión, *recall*, F1 y AUC-ROC, acompañadas de la matriz de confusión.

5 Resultados

5.1 Comparativa de arquitecturas

La Tabla 2 y la Figura 1 resumen la comparativa. ResNet-50 supera a la CNN propia en todas las métricas, con una mejora notable en AUC-ROC (0.946 frente a 0.764) y en F1 (0.803 frente a 0.661). La Figura 2 muestra las matrices de confusión: ambos modelos exhiben *alta precisión pero recall moderado* sobre la clase *cracked*, es decir, cuando predicen “dañada” suelen acertar, pero dejan pasar una fracción relevante de llantas dañadas (falsos negativos). ResNet-50 reduce los falsos negativos de 99 a 65 y los falsos positivos de 15 a 6 respecto de la CNN propia.

Tabla 2: Comparativa en el conjunto de prueba (clase positiva = *cracked*).

Modelo	Parám. entren.	Exactitud	Precisión	<i>Recall</i>	F1	AUC-ROC
CNN propia (desde cero)	0.71M	0.649	0.881	0.529	0.661	0.764
ResNet-50 (<i>transfer</i>)	14.97M	0.782	0.960	0.690	0.803	0.946




Figura 1: Curvas ROC en prueba. ResNet-50 domina a la CNN propia en todo el rango.




Figura 2: Matrices de confusión: CNN propia (izq.) y ResNet-50 (der.).

5.2 Estudio de ablación

Factor 1: aumento de datos. La Tabla 3 (arriba) compara la CNN propia con y sin aumento. El aumento mejora ligeramente el *recall* (0.529 frente a 0.500) y la F1 (0.661 frente a 0.642) de la clase de riesgo, aunque el AUC sin aumento resultó mayor (0.799). El efecto es moderado: con un conjunto tan pequeño y un aumento puramente geométrico, la regularización aportada es limitada.

Factor 2: función de pérdida. La Tabla 3 (abajo) compara entropía cruzada ponderada, simple y focal sobre la CNN propia. La pérdida focal obtiene la mejor F1 (0.683) y el mejor *recall* de la clase *cracked* (0.605), a costa de un AUC algo menor; esto es coherente con su diseño, que prioriza los ejemplos difíciles de la clase positiva.

5.3 Análisis del desbalance de clases

El conjunto presenta un caso instructivo: el desbalance se *invierte* entre entrenamiento (mayoría *normal*, razón 1.15:1) y prueba (mayoría *cracked*, razón 1.83:1). Esta discrepancia de distribución explica la brecha observada entre la F1 de validación (> 0.95 para ResNet-50) y la de prueba (0.80): un clasificador calibrado para la distribución de entrenamiento queda mal calibrado para la de prueba, lo que se manifiesta en un *recall* bajo sobre *cracked* pese a un AUC alto (la ordenación por probabilidad es buena, pero el umbral 0.5 no es óptimo en prueba). Cuantitativamente, comparando estrategias sobre la CNN propia: la *pérdida focal* eleva el *recall* de la clase minoritaria-en-entrenamiento de 0.562 (sin mitigación) a 0.605; la ponderación por clase, en cambio, no aportó mejora neta en este conjunto, probablemente porque el desbalance de entrenamiento es leve y de signo contrario al de prueba. Esto sugiere que, más que reponderar clases, la palanca más efectiva sería recalibrar el umbral de decisión sobre datos representativos de la distribución de despliegue.

5.4 Interpretabilidad (Grad-CAM)

La Figura 3 muestra mapas Grad-CAM de ResNet-50 (activación hacia la clase *cracked*). En las llantas agrietadas, el calor se concentra sobre las fisuras y zonas de pérdida de relieve; en las llantas sanas, la activación hacia “dañada” es difusa o periférica, sin un foco textural claro. Esto aporta evidencia de que el modelo aprende patrones de daño localmente interpretables y no atajos espurios del fondo.

Tabla 3: Ablación sobre la CNN propia (conjunto de prueba; positiva = *cracked*).

Factor	Configuración	Exactitud	<i>Recall</i>	F1	AUC-ROC
Aumento de datos	Con aumento (base)	0.649	0.529	0.661	0.764
	Sin aumento	0.640	0.500	0.642	0.799
Función de pérdida	CE ponderada (base)	0.649	0.529	0.661	0.764
	CE simple	0.643	0.562	0.670	0.760
	Focal ($\gamma=2$)	0.637	0.605	0.683	0.722




Figura 3: Grad-CAM de ResNet-50. Fila superior: imagen original; inferior: mapa de activación hacia la clase *cracked*. El modelo localiza las grietas en las llantas dañadas (columnas 1–3) y no halla foco de daño en las sanas (columnas 4–6).

5.5 Análisis cualitativo de fallos

La Figura 4 presenta los seis errores más confiados de ResNet-50 (mejor modelo). Los seis son *falsos negativos*: llantas realmente agrietadas clasificadas como sanas con probabilidad de daño inferior a 0.03. Las hipótesis, sustentadas en las imágenes, son: (1) varias corresponden a *flancos con relieve/letras en altorrelieve* que dominan la textura y se asemejan a superficies sanas; (2) las grietas finas o localizadas pierden visibilidad al reducir la imagen a 128×128 , eliminando la señal de alta frecuencia; (3) condiciones de iluminación/sobreexposición que reducen el contraste de las fisuras; y (4) el desplazamiento de distribución hacia prueba, que concentra casos de *cracked* visualmente atípicos respecto del entrenamiento. Que el modo de fallo dominante sea el falso negativo es crítico en seguridad y orienta las mejoras futuras.

6 Discusión y limitaciones

Hallazgos. (1) La transferencia de aprendizaje con *fine-tuning* parcial de ResNet-50 supera con holgura a una CNN entrenada desde cero en este régimen de pocos datos, confirmando la transferibilidad de las características de ImageNet. (2) El modo de fallo crítico es el falso negativo sobre la clase de daño. (3) En presencia de desbalance invertido entre particiones, la reponderación de clases es menos efectiva que la pérdida focal, y la recalibración del umbral aparece como la palanca más prometedora.

Limitaciones. (1) *Cómputo*: el entorno fue CPU de un solo núcleo sin GPU; en consecuencia, las imágenes se procesaron a 128×128 (en lugar de los 224 habituales de ResNet), se limitó el número de épocas y el *fine-tuning* fue parcial. Es esperable que resoluciones mayores y un ajuste más extenso aumenten el *recall*. (2) *Tamaño del conjunto*: con ~ 600 imágenes de entrenamiento, la varianza de las estimaciones es alta y el sobreajuste es una amenaza constante. (3) *Desplazamiento de distribución*: la inversión del desbalance y las diferencias visuales entre particiones limitan la generalización del umbral 0.5. (4) *Resolución de Grad-CAM*: los mapas son de baja resolución espacial (4×4 reescalado), útiles cualitativamente pero no para localización fina.

Análisis cualitativo de fallos (ejemplos mal clasificados)



Figura 4: Errores más confiados de ResNet-50: todos son falsos negativos (*cracked* predicho como *normal*).

Trabajo futuro. Aumentar la resolución de entrada y el *fine-tuning*; recalibración de umbral y selección de operación por curva precision–recall; aumento de datos específico de textura (p. ej. recortes de alta resolución centrados en regiones candidatas); validación cruzada para reducir la varianza; y exploración de *backbones* alternativos (EfficientNet, ConvNeXt) con regularización fuerte.

7 Conclusiones

Se desarrolló un sistema reproducible de clasificación de llantas dañadas por textura. ResNet-50 con *fine-tuning* parcial logró AUC-ROC de 0.946 y F1 de 0.803 en prueba, superando claramente a la CNN propia. El estudio de ablación, el análisis de desbalance (con su inversión entre particiones), la interpretabilidad Grad-CAM y el análisis de fallos ofrecen una visión integral: el principal reto pendiente es elevar el *recall* de la clase de daño —reduciendo falsos negativos— mediante mayor resolución, recalibración de umbral y datos más representativos de la distribución de despliegue.

Reproducibilidad. Todo el código, la especificación de entorno (`requirements.txt`) y las instrucciones de ejecución de extremo a extremo con un único comando se incluyen en el repositorio que acompaña a este informe.

Referencias

- Mateusz Buda, Atsuto Maki, and Maciej A Mazurowski. A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, 106:249–259, 2018.
- Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 248–255, 2009.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

- Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning (ICML)*, pages 448–456, 2015.
- Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 25, 2012.
- Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.
- Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.
- Connor Shorten and Taghi M Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1):1–48, 2019.
- Joshua Siegel. Oxidized and non-oxidized tire sidewall and tread images, 2021. Versión V1.
- Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.
- Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 27, 2014.