
Segmentación de Vasos Retinianos para la Detección de Retinopatía Diabética: U-Net++ implementada desde cero, estudio de ablación y adaptación de dominio DRIVE→CHASE_DB1

Paul Bazan H. Valeria P. Bulege N. Oscar Dante Chaiña A.
Elias O. Diaz C. Miguel A. Tasayco M.

Grupo N.º 1 — Maestría en Inteligencia Artificial (2026-1)
Escuela de Posgrado, Universidad Nacional de Ingeniería (UNI), Perú

Curso: Redes Neuronales y Aprendizaje Profundo Docente: Ph.D. Aldo Camargo

Examen Parcial — Pregunta 2

Abstract

La retinopatía diabética es una de las principales causas de ceguera prevenible, y su tamizaje temprano depende de la segmentación precisa de la red vascular en imágenes de fondo de ojo. Presentamos una implementación *desde cero* en PyTorch de U-Net y de su variante con conexiones de salto densas anidadas, U-Net++, para segmentación binaria píxel a píxel de vasos retinianos. Realizamos un estudio de ablación sobre tres ejes —arquitectura (U-Net vs. U-Net++), función de pérdida (BCE vs. Dice vs. combinada) y profundidad de la red— y evaluamos el modelo ganador in-distribution sobre DRIVE con métricas de sensibilidad, especificidad, F1 y AUC-ROC. A continuación cuantificamos el cambio de dominio entrenando en DRIVE y evaluando sin adaptación en CHASE_DB1, analizamos cualitativamente qué tipos de vaso (capilares finos vs. vasos gruesos) resultan más difíciles de segmentar y por qué desde una perspectiva arquitectónica, e implementamos y comparamos tres estrategias de mitigación de la brecha entre dominios: preprocesamiento con CLAHE, *test-time augmentation* (TTA) y *fine-tuning* de pocos ejemplos del dominio objetivo. Todo el código es reproducible con un único comando y semilla fija. Los componentes arquitectónicos principales fueron implementados por los autores sin reutilizar bibliotecas de segmentación existentes.

1 Introducción y motivación

La retinopatía diabética (RD) es una complicación microvascular de la diabetes y una causa principal de ceguera prevenible a nivel mundial. El tamizaje poblacional mediante fotografía de fondo de ojo (imágenes de *fundus*) permite detectar la enfermedad en estadios tratables, pero su escalabilidad está limitada por la disponibilidad de oftalmólogos. La segmentación automática de la red vascular es un paso intermedio clave: la morfología, el calibre y la tortuosidad de los vasos son biomarcadores de la progresión de la RD, y una máscara vascular fiable habilita mediciones cuantitativas reproducibles.

Desde el punto de vista del aprendizaje profundo, la segmentación de vasos es un problema de *predicción densa*: el modelo debe asignar a cada píxel una etiqueta binaria (vaso / fondo). El reto es particular por tres razones. Primero, el fuerte desbalance de clases: en los conjuntos estándar el primer plano (vasos) ocupa aproximadamente entre el 9 % y el 17 % de los píxeles dentro del campo de visión (12,5 % en promedio en DRIVE), lo que penaliza pérdidas centradas en la exactitud píxel a píxel.

Segundo, la estructura multiescala: coexisten arterias y venas gruesas con capilares de 1–2 píxeles de ancho que se confunden con el ruido. Tercero —y central en este trabajo— la *generalización entre dominios*: un modelo entrenado en un conjunto clínico tiende a degradarse cuando se evalúa sobre imágenes adquiridas con otra cámara, otro campo visual o sobre otra población de pacientes, un fenómeno conocido como *domain shift* que es decisivo para el despliegue clínico real.

Este informe aborda esos tres retos. Nuestras contribuciones son: (i) una implementación propia y documentada de U-Net y U-Net++ en PyTorch, sin copiar código de bibliotecas de segmentación; (ii) un estudio de ablación que aísla el efecto de la arquitectura, de la función de pérdida y de la profundidad de la red; (iii) una evaluación in-distribution sobre DRIVE y una medición explícita de la brecha de generalización DRIVE→CHASE_DB1 con análisis de sus causas; y (iv) la implementación y comparación de tres estrategias de adaptación de dominio con evidencia cuantitativa de su efecto sobre dicha brecha.

2 Trabajos relacionados

Arquitecturas encoder–decoder. La U-Net [Ronneberger et al., 2015] estableció el paradigma encoder–decoder con *skip connections* para segmentación biomédica con pocas muestras: el camino contractivo captura contexto y el expansivo recupera localización, conectando ambos por concatenación de mapas de igual resolución. U-Net++ [Zhou et al., 2018] observa que esas conexiones directas saltan entre representaciones de profundidades muy distintas, creando una *brecha semántica*; para reducirla introduce nodos intermedios densos que resintetizan progresivamente las características antes de fusionarlas en el decoder, junto con la posibilidad de *deep supervision*. Attention U-Net [Oktay et al., 2018] añade compuertas de atención que suprimen activaciones irrelevantes en los *skips*.

Segmentación de vasos retinianos. Sobre los *benchmarks* clásicos, Vessel-Net [Wu et al., 2019] emplea supervisión multicamino con bloques inception-residuales, y SA-UNet [Guo et al., 2020] incorpora un módulo de atención espacial y *structured dropout*, reportando resultados estado del arte en DRIVE y CHASE_DB1 con muy pocos parámetros. Estas líneas confirman que el cuello de botella de la U-Net estándar para vasos finos puede mitigarse densificando o atendiendo las conexiones de salto, motivación directa de nuestra elección de U-Net++.

Funciones de pérdida para clases desbalanceadas. La pérdida de Dice [Milletari et al., 2016] optimiza directamente el solapamiento y es robusta al desbalance, a diferencia de la entropía cruzada binaria (BCE), que tiende a favorecer el fondo mayoritario. Las pérdidas combinadas BCE+Dice equilibran estabilidad de gradiente y sensibilidad al primer plano.

Conjuntos de datos y dominio. DRIVE [Staal et al., 2004] es el *benchmark* de referencia (40 imágenes, división fija). STARE [Hoover et al., 2000] aporta dobles anotaciones de expertos. CHASE_DB1 [Fraz et al., 2012] se adquirió con una cámara distinta y sobre una población pediátrica, lo que lo hace idóneo para estudiar generalización entre dominios. Para mitigar el cambio de dominio sin reentrenar exhaustivamente, recurrimos a ecualización adaptativa de histograma con límite de contraste (CLAHE) [Zuiderveld, 1994] y a *test-time augmentation*.

3 Metodología

3.1 U-Net base implementada desde cero

Nuestra U-Net sigue el diseño original [Ronneberger et al., 2015] con un bloque constructivo DoubleConv (Conv 3×3 →BN→ReLU, dos veces, con *padding*= 1 para preservar resolución). El *encoder* encadena Down = MaxPool 2×2 →DoubleConv; el *decoder* usa Up = *upsampling* bilineal→concatenación del *skip*→DoubleConv, con un relleno defensivo de ± 1 píxel para casos de *pooling* impar. El número de canales por nivel es $c_i = c_{\text{base}} \cdot 2^i$. La capa final es una convolución 1×1 que produce *logits* sin sigmoide (la activación se aplica en la pérdida o en la inferencia). Todos los bloques fueron escritos por los autores; no se usaron implementaciones de bibliotecas de segmentación.

3.2 U-Net++ con conexiones de salto densas anidadas

Sobre la misma base implementamos U-Net++ [Zhou et al., 2018]. Definimos una grilla de nodos $X^{i,j}$, donde i indexa el nivel de resolución ($i = 0$ resolución completa, $i = L$ cuello de botella) y j la columna ($j = 0$ es el *encoder*; $j > 0$ son los nodos densos del *decoder*). Cada nodo se calcula como:

$$X^{i,j} = H [X^{i,0}, X^{i,1}, \dots, X^{i,j-1}, U(X^{i+1,j-1})] , \quad (1)$$

donde $H(\cdot)$ es un DoubleConv, $[\cdot]$ la concatenación en canales y U el *upsampling* bilineal. En consecuencia, el número de canales de entrada de $X^{i,j}$ ($j \geq 1$) es

$$\text{in_ch}(i, j) = j \cdot c_i + c_{i+1}, \quad (2)$$

es decir, j *dense skips* del mismo nivel más un *upsample* del nivel inferior. Esta densificación acorta la brecha semántica entre *encoder* y *decoder* y, en principio, recupera información de vasos finos que el cuello de botella descarta. Implementamos opcionalmente *deep supervision* con una cabeza de salida por columna del nivel superior.

3.3 Funciones de pérdida

Comparamos tres pérdidas, todas operando sobre *logits* de forma $[B, 1, H, W]$ y objetivos del mismo tamaño en punto flotante: **BCE** (binary_cross_entropy_with_logits); **Dice suave**,

$$L_{\text{Dice}} = 1 - \frac{2 \sum p g + \epsilon}{\sum p + \sum g + \epsilon}, \quad p = \sigma(\text{logits}), \quad g = \text{objetivo}; \quad (3)$$

y **combinada** $L = L_{\text{BCE}} + \alpha L_{\text{Dice}}$ con $\alpha = 0.5$. El estadístico de desbalance medido sobre el conjunto de entrenamiento (razón de primer plano medida en DRIVE: $\approx 12.5\%$ dentro del FOV) justifica incorporar el término Dice.

3.4 Diseño del estudio de ablación

El ablation aísla tres decisiones (Sección 5.1): **(A) arquitectura** —U-Net vs. U-Net++ a igual c_{base} y profundidad—; **(B) función de pérdida** —BCE vs. Dice vs. combinada sobre U-Net—; y **(C) profundidad** —U-Net++ con 4 vs. 3 niveles—. Las cinco configuraciones se entrenan bajo idéntico protocolo y semilla.

3.5 Estrategias de adaptación de dominio

Implementamos tres mecanismos para reducir la brecha DRIVE→CHASE sin modificar la arquitectura: **CLAHE** en el canal de luminancia del espacio LAB (preprocesamiento de costo nulo en inferencia); **TTA**, promediando las probabilidades de seis transformaciones simétricas (original, volteos horizontal/vertical y rotaciones de $90^\circ/180^\circ/270^\circ$, cada una revertida antes de promediar); y **fine-tuning de pocos ejemplos**, congelando el *encoder* y ajustando únicamente el *decoder* y la cabeza con 5 imágenes anotadas de CHASE_DB1, evaluando sobre el resto no visto.

4 Configuración experimental

Datos. DRIVE [Staal et al., 2004] provee 20 imágenes de entrenamiento con máscara manual de vasos y máscara de campo de visión (FOV). El conjunto de prueba oficial se distribuye *sin* anotaciones de vasos públicas; por ello, para una evaluación con verdad de terreno, construimos una partición interna reproducible 13/2/5 (entrenamiento/validación/prueba) sobre las 20 imágenes anotadas, con semilla fija. Las métricas se calculan únicamente dentro del FOV mediante las máscaras training/mask. Las 20 imágenes de prueba oficiales (con su FOV) quedan disponibles para inferencia cualitativa, pero no para métricas al carecer de etiqueta. CHASE_DB1 [Fraz et al., 2012] (28 imágenes, cámara distinta) se reserva íntegramente como dominio objetivo para el experimento de generalización. La Figura 1 muestra ejemplos del conjunto con su máscara de vasos.

Preprocesamiento y aumentación. Las imágenes se redimensionan a 256×256 (T4) o 512×512 (A100) y se normalizan con la media y desviación de ImageNet. La aumentación de entrenamiento (con *augmentations*) incluye rotaciones de 90° , volteos, ShiftScaleRotate, ajuste de brillo/contraste y ruido gaussiano. Las máscaras se interpolan con vecino más cercano y se

binarizan en el umbral 127.




Figura 1: Muestras de DRIVE (entrenamiento): fila superior, imágenes de fondo de ojo; fila inferior, su máscara manual de vasos (verdad de terreno). La densidad del árbol vascular y el predominio de capilares finos ilustran el desbalance de clases y la dificultad de la tarea.

Entrenamiento. Optimizador Adam [Kingma y Ba, 2015] ($lr=10^{-3}$, *weight decay* 10^{-5}), planificador *cosine annealing*, 60 épocas, precisión mixta (*float16*) y recorte de norma de gradiente a 1.0. Se selecciona el modelo por mejor F1 de validación. La reproducibilidad se garantiza con semilla global (= 42) y *cuDNN* determinista.

Métricas. Reportamos sensibilidad (recall de vasos), especificidad, F1 y AUC-ROC, calculadas a nivel de píxel sobre el conjunto completo con umbral 0.5.

5 Resultados

5.1 Estudio de ablación (DRIVE validación)

La Tabla 1 resume las cinco configuraciones. El modelo seleccionado para las fases siguientes es **H** (mejor F1 de validación).

Tabla 1: Estudio de ablación sobre la validación interna de DRIVE. Ejes: arquitectura, función de pérdida y profundidad.

Configuración	Parámetros	F1	AUC-ROC	Sensib.	Especif.
U-Net + BCE	H	H	H	H	H
U-Net + Dice	H	H	H	H	H
U-Net + BCE+Dice	H	H	H	H	H
U-Net++ + BCE+Dice (4 niv.)	H	H	H	H	H
U-Net++ + BCE+Dice (3 niv.)	H	H	H	H	H

Lectura esperada. Tres hipótesis verificables guiaron el diseño: (a) si $F1(\text{Dice}) > F1(\text{BCE})$, el desbalance ($\approx 12,5\%$ de primer plano) penaliza a la BCE pura; (b) si $F1(\text{U-Net++}) > F1(\text{U-Net})$ a igual pérdida, las conexiones densas aportan en la captura de capilares finos que desaparecen en el cuello de botella de la U-Net estándar; (c) si 4 niveles superan a 3, la mayor profundidad captura más contexto global de la retina. La conclusión definitiva se sustenta en los valores de la Tabla 1.






Figura 2: Curvas de entrenamiento por configuración. La comparación entre pérdidas evidencia el efecto del término Dice frente a BCE puro bajo el desbalance de clases.

5.2 Evaluación in-distribution sobre DRIVE

La Tabla 2 compara nuestro modelo ganador con valores reportados en la literatura sobre DRIVE. *Nota:* como la verdad de terreno del test oficial no es pública, nuestras métricas se calculan sobre la partición interna de prueba (5 imágenes, restringidas al FOV); la comparación con la literatura (test oficial de 20 imágenes) es por tanto indicativa.

Tabla 2: Evaluación in-distribution sobre DRIVE y comparativa con la literatura.

Método	Sensib.	Especif.	F1	AUC-ROC
U-Net [Ronneberger et al., 2015]	0.7537	0.9820	0.8142	0.9755
Vessel-Net [Wu et al., 2019]	0.8038	0.9802	0.8189	0.9821
SA-UNet [Guo et al., 2020]	0.8212	0.9840	0.8212	0.9864
[−] (nuestro)	[−]	[−]	[−]	[−]






Figura 3: Curva ROC del modelo ganador en el conjunto de prueba de DRIVE.

5.3 Generalización entre conjuntos: DRIVE → CHASE_DB1

Entrenando exclusivamente en DRIVE y evaluando sin adaptación en CHASE_DB1 medimos la brecha de rendimiento (Tabla 3). Esta degradación es el punto de partida cuantitativo para las estrategias de mitigación de la Sección 7.

Causas de la brecha. La degradación se atribuye a (i) diferencias de cámara y campo visual —CHASE captura más periferia retiniana y a otra resolución—; (ii) distinta distribución de histograma e iluminación (Figura 4); y (iii) diferencias morfológicas de la población (pacientes pediátricos en CHASE frente a adultos en DRIVE). El desplazamiento de las distribuciones por canal de color es la señal más directa de *covariate shift* a la entrada del modelo.

6 Análisis cualitativo de fallos

Separamos los vasos por grosor mediante morfología matemática: los *capilares finos* se obtienen como la diferencia entre la máscara y su erosión con un elemento estructurante 3×3 , y los *vasos gruesos* como la erosión con un elemento 7×7 . Para cada categoría medimos la tasa de falsos negativos (FN). La Tabla 4 resume el resultado.

Tabla 3: Brecha de generalización DRIVE→CHASE_DB1 (evaluación *zero-shot*, sin adaptación).

Conjunto	Sensib.	Especif.	F1	AUC-ROC
DRIVE (test, in-distribution)	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$
CHASE_DB1 (<i>zero-shot</i>)	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$
Brecha Δ	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$




Figura 4: Análisis del cambio de dominio: comparación de histogramas por canal y predicción *zero-shot* sobre CHASE_DB1 con su mapa de error.

Interpretación arquitectónica. Esperamos —y la Tabla 4 lo verifica— una tasa de FN sustancialmente mayor en capilares finos que en vasos gruesos. La razón es estructural: con `IMG_SIZE = 256` y cuatro niveles de *pooling*, el cuello de botella opera a $1/16$ de la resolución (16×16), de modo que un vaso de 1–2 píxeles queda por debajo de la resolución efectiva y no deja rastro recuperable en las capas profundas. Las conexiones densas de U-Net++ mitigan parcialmente este efecto al propagar características de alta resolución por los nodos intermedios, pero no lo eliminan. Los falsos positivos, por su parte, predominan en zonas de baja iluminación y en el borde del disco óptico, donde el contraste local imita la apariencia de un vaso.

7 Adaptación de dominio: resultados

La Tabla 5 compara las tres estrategias sobre el mismo subconjunto no visto de CHASE_DB1, frente a la línea base *zero-shot*.

Marco de análisis. CLAHE ataca directamente el contraste de los vasos en imágenes con iluminación no uniforme, a costo nulo en inferencia. El TTA reduce la varianza de la predicción al promediar transformaciones simétricas y suele beneficiar más a la especificidad que a la sensibilidad. El *fine-tuning* de pocos ejemplos tiene el mayor potencial de mejora en F1 al adaptar el decoder al estilo visual de CHASE, pero requiere 5 imágenes anotadas del dominio objetivo. La elección final debe ponderar la ganancia en F1 frente al costo de obtener anotaciones del dominio objetivo: cuando estas no están disponibles, CLAHE+TTA ofrecen la mejor relación costo/beneficio sin etiquetas.

8 Discusión crítica y limitaciones

Nuestro estudio tiene limitaciones que conviene explicitar. Primero, la verdad de terreno del **test oficial de DRIVE no se distribuye públicamente**; por ello evaluamos sobre una partición interna de 5 imágenes (métricas restringidas al FOV), lo que introduce mayor varianza y hace que la comparación con la literatura sea indicativa y no estrictamente equivalente. Además, las métricas en DRIVE se calculan dentro del FOV mientras que en CHASE_DB1 —al no disponer de sus máscaras de FOV— se hacen sobre el cuadro completo, asimetría que conviene homogeneizar.

Segundo, trabajamos a **resolución reducida** (256×256 en T4), lo que —como discutimos— limita estructuralmente la detección de capilares finos; una resolución de 512×512 o el entrenamiento por *parches* probablemente reducirían la tasa de FN en vasos finos. Tercero, el **umbral fijo de 0.5** no se optimizó por dominio; un umbral calibrado en CHASE podría recuperar parte de la brecha sin reentrenar. Cuarto, reportamos un **único seed** para los modelos finales: una estimación rigurosa requeriría varias semillas e intervalos de confianza. Quinto, no incorporamos el **análisis de concordancia entre anotadores** que habilitaría STARE, lo que acotaría el techo de rendimiento alcanzable. Finalmente, el *fine-tuning* de pocos ejemplos asume disponibilidad de anotaciones del dominio objetivo, supuesto que puede no cumplirse en despliegue; mantuvimos una separación estricta entre las imágenes de ajuste y las de evaluación para evitar fuga de información.

Tabla 4: Tasas de error por tipo de estructura vascular sobre DRIVE test.

Métrica	Valor
FN en capilares finos (≤ 3 px)	$\downarrow$
FN en vasos gruesos (> 7 px)	$\downarrow$
Tasa de falsos positivos (fondo)	$\downarrow$




Figura 5: Análisis cualitativo de fallos: predicción, máscaras de vasos finos y gruesos, y mapas de FN/FP.

A nivel metodológico, el principal aprendizaje es que la brecha entre dominios es atribuible en gran medida a *covariate shift* de bajo nivel (color, contraste, campo visual), que estrategias económicas como CLAHE y TTA atacan de forma efectiva; la fracción de la brecha imputable a diferencias morfológicas de la población solo se cierra con adaptación supervisada (*fine-tuning*).

9 Conclusiones

Implementamos desde cero U-Net y U-Net++ para segmentación de vasos retinianos, aislamos mediante ablación el efecto de la arquitectura, la pérdida y la profundidad, y cuantificamos explícitamente la degradación al transferir de DRIVE a CHASE_DB1. El análisis de fallos confirma que los capilares finos son la estructura más difícil por razones de resolución efectiva del cuello de botella, y las tres estrategias de adaptación evaluadas reducen la brecha entre dominios en distinta medida y costo. El código es reproducible de extremo a extremo con semilla fija y un único comando documentado.

Tabla 5: Efecto de cada estrategia de adaptación de dominio sobre CHASE_DB1.

Estrategia	Sensib.	Especif.	F1	AUC-ROC
Línea base (<i>zero-shot</i>)	[H]	[H]	[H]	[H]
CLAHE (preprocesamiento)	[H]	[H]	[H]	[H]
TTA (6 transformaciones)	[H]	[H]	[H]	[H]
<i>Fine-tuning</i> (5 imágenes)	[H]	[H]	[H]	[H]




Figura 6: Efecto de CLAHE, TTA y *fine-tuning* sobre las cuatro métricas en CHASE_DB1; las líneas discontinuas marcan el rendimiento de referencia en DRIVE.

Referencias

- Fraz, M. M., Remagnino, P., Hoppe, A., Uyyanonvara, B., Rudnicka, A. R., Owen, C. G., y Barman, S. A. An ensemble classification-based approach applied to retinal blood vessel segmentation. *IEEE Transactions on Biomedical Engineering*, 59(9):2538–2548, 2012.
- Guo, C., Szemenyei, M., Yi, Y., Wang, W., Chen, B., y Fan, C. SA-UNet: Spatial Attention U-Net for Retinal Vessel Segmentation. En *25th International Conference on Pattern Recognition (ICPR)*, págs. 1236–1242. IEEE, 2020.
- Hoover, A., Kouznetsova, V., y Goldbaum, M. Locating blood vessels in retinal images by piecewise threshold probing of a matched filter response. *IEEE Transactions on Medical Imaging*, 19(3):203–210, 2000.
- Kingma, D. P., y Ba, J. Adam: A method for stochastic optimization. En *International Conference on Learning Representations (ICLR)*, 2015.
- Milletari, F., Navab, N., y Ahmadi, S.-A. V-Net: Fully convolutional neural networks for volumetric medical image segmentation. En *Fourth International Conference on 3D Vision (3DV)*, págs. 565–571, 2016.
- Oktay, O., Schlemper, J., Folgoc, L. L., Lee, M., Heinrich, M., Misawa, K., Mori, K., McDonagh, S., Hammerla, N. Y., Kainz, B., Glocker, B., y Rueckert, D. Attention U-Net: Learning where to look for the pancreas. *arXiv preprint arXiv:1804.03999*, 2018.
- Ronneberger, O., Fischer, P., y Brox, T. U-Net: Convolutional networks for biomedical image segmentation. En *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, LNCS 9351, págs. 234–241. Springer, 2015.
- Staal, J., Abràmoff, M. D., Niemeijer, M., Viergever, M. A., y van Ginneken, B. Ridge-based vessel

- segmentation in color images of the retina. *IEEE Transactions on Medical Imaging*, 23(4):501–509, 2004.
- Wu, Y., Xia, Y., Song, Y., Zhang, Y., y Cai, W. Vessel-Net: Retinal vessel segmentation under multi-path supervision. En *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, págs. 264–272. Springer, 2019.
- Zhou, Z., Rahman Siddiquee, M. M., Tajbakhsh, N., y Liang, J. UNet++: A nested U-Net architecture for medical image segmentation. En *Deep Learning in Medical Image Analysis (DLMLA)*, LNCS 11045, págs. 3–11. Springer, 2018.
- Zuiderveld, K. Contrast limited adaptive histogram equalization. En *Graphics Gems IV*, págs. 474–485. Academic Press, 1994.